MINISTÈRE
DE L'AGRICULTURE
ET DE LA SOUVERAINETÉ
ALIMENTAIRE

Liberté
Égalité
Fraternité

Formation-R-perfectionnement

Module Rappels et compléments sur R et RStudio

MINISTÈRE
DE L'AGRICULTURE
DE LA SOUVERAINETÉ
ALIMENTAIRE ET DE LA FORÊT
Liberté
Égalité
Fraternité

Sommaire

MINISTÈRE
DE L'AGRICULTURE
ET DE LA SOUVERAINETÉ
ALIMENTAIRE

Liberté
Égalité
Fraternité

0.1 Avant-propos

Ce diaporama de formation a été rédigé dans le but d'être le support visuel des formations dispensées au MASA.

Ces formations s'adressent à des agents qui ont suivi [la formation R initiation][https://ssm-agriculture.github.io/formation-R-initiation/] ou qui sont familiers des outils de manipulation de données (dplyr).

MINISTÈRE
DE L'AGRICULTURE
ET DE LA SOUVERAINETÉ
ALIMENTAIRE

Liberté
Égalité
Fraternité

0.2 Avant-propos

Elles sont données en présentiel sur une durée **de 3 jours**, les modules de cette formation sont ajustables suivants le choix des agents.

Champ couvert par cette formation

Ce support couvre les rappels et compléments sur R et l'environnement du MASA.

Pour information, les modules de la formation R-perfectionnement sont:

- 01 - Module Rappels
- 02 - Module Fonctions
- 03 - Module Cartes statiques et interactives
- 04 - Module Création de graphiques avec ggplot2
- 05 - Module Quarto
- 06 - Module Parquet
- 07 - Module Initiation à l'écriture d'applications Shiny

Ils sont orientés pour être utile aux agents du SSM Agriculture et se concentrent sur une utilisation de R via RStudio qui est mise à disposition des agents sur la plateforme interne Cerise basée sur RStudio Workbench.

MINISTÈRE
DE L'AGRICULTURE
ET DE LA SOUVERAINETÉ
ALIMENTAIRE

Liberté
Égalité
Fraternité

1 Travailler avec R au ministère

MINISTÈRE
DE L'AGRICULTURE
ET DE LA SOUVERAINETÉ
ALIMENTAIRE
Liberté
Égalité
Fraternité

1.1 Présentation

Logiciel de traitement de données et analyse statistique :

- offre un environnement interactif de développement statistique, analytique et graphique ;
- est doté d'un langage de programmation R ;
- permet d'accéder à des données, de les manipuler et les analyser ;
- S'interface avec les bases de données : Oracle, SYBASE, PostgreSQL, SQLITE…

Remplace SAS ou SPSS

Logiciel IDE : Integrated Development Environment

MINISTÈRE
DE L'AGRICULTURE
ET DE LA SOUVERAINETÉ
ALIMENTAIRE
Liberté
Égalité
Fraternité

1.2 Comment travailler avec R au MASA ?

Depuis la plate-forme **CERISE** :

- ⇒ Adresse : https://rstudio.agriculture.rie.gouv.fr
- ⇒ PISTACHE : Pistache > Traitements statistiques et Diffusion > R > Migration SPSS et SAS vers R > Accès au WIKI Cerise - R > Accéder à Cerise

Cerise permet l'**accès aux ressources déposées sur le serveur**, la **sauvegarde**, le **partage de code** et le **travail simultané.** C'est l'usage recommandé.

En **local sur son poste**

Non préconisée

Existence d'une plate-forme CERISE de **Préproduction** :
https://rstudio-pprd.agriculture.rie.gouv.fr

MINISTÈRE
DE L'AGRICULTURE
ET DE LA SOUVERAINETÉ
ALIMENTAIRE

Liberté
Égalité
Fraternité

1.3 Fenêtres dans RSTUDIO

Vue des scripts et des données

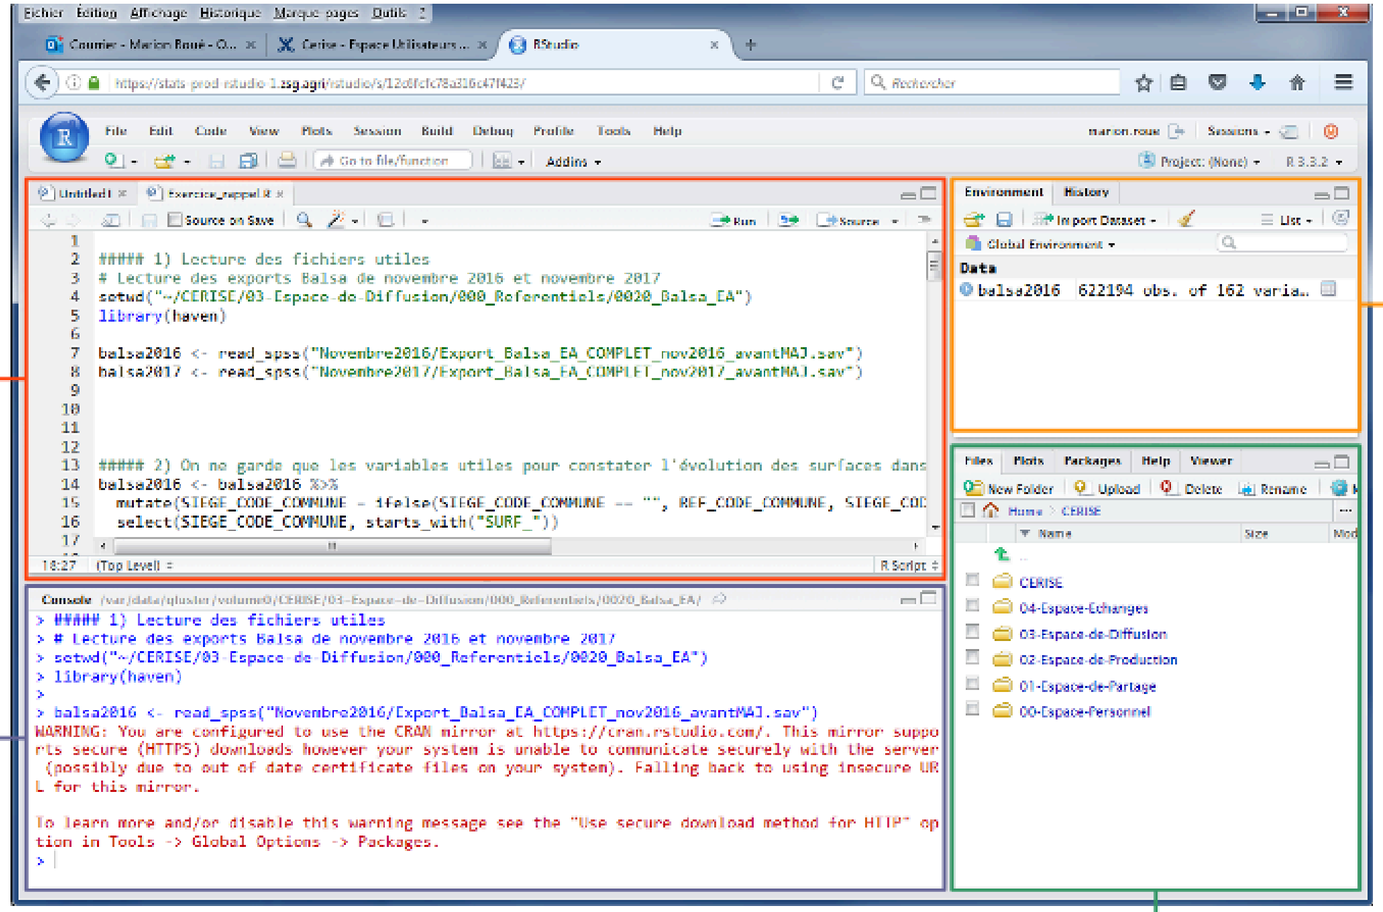

Vue des éléments en mémoire et de l'historique des commandes

Console

Vue des répertoires, des graphiques, des packages et de l'aide

MINISTÈRE
DE L'AGRICULTURE
ET DE LA SOUVERAINETÉ
ALIMENTAIRE
Liberté
Égalité
Fraternité

1.4 Organisation sous CERISE

Cerise est organisé en plusieurs répertoires :

- **00-Espace-Personnel** => espaces personnels des agents, **accessible par l'agent uniquement**
- **01-Espace-de-Partage** => lieu de partage général entre les différents acteurs
- **02-Espace-de-Production** => plateforme de stockage des données brutes collectées, ainsi que des fichiers de données et programmes issus des traitements statistiques réalisés par l'équipe projet
- **03-Espace-de-Diffusion** => mise à disposition au sein du SSM des données issues des traitements statistiques réalisés en amont => Ces deux derniers espaces sont découpés par opérations statistiques
- **04-Espace-Echanges** => stockage des fichiers de données à transmettre aux autres applications du SI CASSIS (par exemple Agreste) ainsi qu'aux SI des partenaires extérieurs

MINISTÈRE
DE L'AGRICULTURE
ET DE LA SOUVERAINETÉ
ALIMENTAIRE
Liberté
Égalité
Fraternité

1.5 Généralités sur R avec RStudio

On utilise des packages (ensemble de fonctions) qu'il faut installer puis charger (sinon erreur!). Par exemple:

- `install.packages("rio")`
- `library(rio)` ou `require(rio)`

Pour obtenir de l'aide sur une fonction :

- `?maFonction`
- double-clic sur le nom de la fonction et F1

Quelques raccourcis claviers usuels:

- Ctrl + Entrée : exécuter la ligne de code actuelle (curseur) ou une sélection
- Ctrl + Shift + C : mettre une ligne en commentaires
- Ctrl + Shift + M : Écrire un pipe %>% ou avec la nouvelle écriture |>

MINISTÈRE
DE L'AGRICULTURE
ET DE LA SOUVERAINETÉ
ALIMENTAIRE

Liberté
Égalité
Fraternité

2 Traitement de données avec {dplyr} et {tidyr}

MINISTÈRE
DE L'AGRICULTURE
ET DE LA SOUVERAINETÉ
ALIMENTAIRE

Liberté
Égalité
Fraternité

2.1 Les tables de données

Dans une table de données, on peut vouloir :

- sélectionner des lignes ou des colonnes particulières
- créer de nouvelles variables
- réaliser des calculs ou des opérations sur tout ou partie des observations
- faire une jointure avec une autre table
- transposer ou faire pivoter la table
- etc.

Untitled1* × bzh ×

Filter

	Annee	Numero_Region	libelle_Region	Numero_Dept	Libelle_Dept	Code	Libelle	nb_exp	SurfAB
1	2016	53	BRETAGNE	22	COTES-D'ARMOR	AFO	Cultures fourragères	374	8895.
2	2016	53	BRETAGNE	22	COTES-D'ARMOR	AGR	Agrumes	1	
3	2016	53	BRETAGNE	22	COTES-D'ARMOR	ALL	TOUTES PV	530	16389.
4	2016	53	BRETAGNE	22	COTES-D'ARMOR	AU	Autres	199	431.
5	2016	53	BRETAGNE	22	COTES-D'ARMOR	CE	Céréales	265	3189.

MINISTÈRE
DE L'AGRICULTURE
ET DE LA SOUVERAINETÉ
ALIMENTAIRE
Liberté
Égalité
Fraternité

2.2 Packages *dplyr* et *tidyr*

- Objectif de *dplyr* : rassembler dans un seul package les outils de manipulation de données les plus importants pour l'analyse des données

  ⇒ ensemble de fonctions correspondant à un ensemble d'opérations élémentaires

- *dplyr* est un package, issu du la collection *tidyverse*, qui a pour objectif de faciliter la manipulation de tableaux.
- Deux principes pour les packages *dplyr* et *tidyr* :
  - **Usage de fonctions « verbe »** toutes construites sur le même principe : le 1er paramètre est la table de données sur laquelle on travaille. Les noms de variable n'ont pas besoin d'être en guillemets
  - **Usage de l'opérateur pipe** (%>% ou |>). Avec RStudio, le raccourci clavier pour cet opérateur est : **Ctrl + Shift + M**. Permet d'enchaîner les fonctions sans les emboîter:

```
maTable |> select(noms_des_colonnes) |> filter(conditions) |>  summarise(total=sum(maVariable))
# Au lieu de :
summarise(filter(select(maTable,noms_des_colonnes),conditions),total=sum(maVariable))
```

MINISTÈRE
DE L'AGRICULTURE
ET DE LA SOUVERAINETÉ
ALIMENTAIRE
Liberté
Égalité
Fraternité

2.3 Filtre et sélection dans une table

- Pour filtrer les lignes dans une table à l'aide de conditions logiques, on utilise la fonction `filter()`

  `maTable %>% filter(conditions)`

- Pour sélectionner des colonnes dans une table, on utilise la fonction `select()`

  `maTable %>% select(noms_des_colonnes)`

ma_table %>% filter(Profession == "Militaire")

ma_table %>% filter(Age < 30) %>% select(Nom_prenom)

row.names	Nom_prenom	Profession	Age	Code_postal_residence
1	Millot Nicolas	Manutentionnaire	26	29280
2	Roué Benjamin	Ingénieur	27	92130
3	Marzin Raymond	Militaire	56	83000

MINISTÈRE
DE L'AGRICULTURE
ET DE LA SOUVERAINETÉ
ALIMENTAIRE
Liberté
Égalité
Fraternité

2.4 Sélection des colonnes dans une table

Différentes façons de sélectionner :

- En nommant chaque variable une à une : `select(Nom_prenom, Age)`
- En indiquant un vecteur de variables consécutives : `select(Nom_prenom:Code_postal_residence)`
- En donnant les indices des variables : `select(1:3)`
- Grâce à de la sélection avec des opérateurs “helpers” (contient, commence par, finit par… : `select(contains("a"),starts_with("P"),ends_with("E"),where(is.numeric), last_col())`
- En enlevant celles dont on ne veut pas : `select(-Age)` ou `select(!(Age:Code_postal_residence))`

MINISTÈRE
DE L'AGRICULTURE
ET DE LA SOUVERAINETÉ
ALIMENTAIRE
Liberté
Égalité
Fraternité

2.5 Création ou modification de variables dans une table (1/2)

Avec le package **dplyr**, on utilise la fonction `mutate()` qui permet de créer plusieurs variables à la fois :

- `table ← table %>% mutate(new_var1 = var1, newvar2 = var2)` → formule générique
- `table ← table %>% mutate(new_var1 = constante)` → création d'une constante
- `table ← table %>% mutate(new_var2 = fonction(var1))` → création à partir d'une formule
- `table ← table %>% mutate(new_var3 = var1 + var2)` → création à partir d'opérations arithmétiques
- `table ← table %>% mutate(new_var4 = vecteur1)` → création à partir de variables externes

Pour modifier une variable, on affecte la nouvelle valeur à une variable existante.

MINISTÈRE
DE L'AGRICULTURE
ET DE LA SOUVERAINETÉ
ALIMENTAIRE
Liberté
Égalité
Fraternité

2.6 Création ou modification de variables dans une table (2/2)

- Paramètres utiles pour aller plus loin :
  - .after ou .before : pour placer la variable où on le souhaite (dernière colonne par défaut) (pour éviter un `relocate()` après)
  - .keep : pour choisir si on garde les variables qui servent à construire une nouvelle variable (pour éviter un `select(-var1,-var2)` après)

```
table ← table %>% mutate(new_var1 = var1+var2, .after=ident,.keep="unused")
```

Dans cet exemple, la nouvelle variable `new_var1` est placée après `ident`, `var1` et `var2` sont supprimés

MINISTÈRE
DE L'AGRICULTURE
ET DE LA SOUVERAINETÉ
ALIMENTAIRE

Liberté
Égalité
Fraternité

2.7 La fonction reframe (1/4)

Avez-vous déjà rencontré ce message d'avertissement lorsque vous utilisez la fonction `summarise()` ?

```
Warning message:
Returning more (or less) than 1 row per `summarise()` group was
deprecated in dplyr 1.1.0.
ℹ Please use `reframe()` instead.
ℹ When switching from `summarise()` to `reframe()`, remember that
  `reframe()` always returns an ungrouped data frame and adjust
  accordingly.
```

Si oui, vous pouvez vous en débarasser en utilisant la fonction `reframe()`.

MINISTÈRE
DE L'AGRICULTURE
ET DE LA SOUVERAINETÉ
ALIMENTAIRE

Liberté
Égalité
Fraternité

2.8 La fonction reframe (2/4)

Par rapport à la fonction `summarise()`, la fonction `reframe()` (dplyr >= 1.1.0) est utile lorsqu'on souhaite **retourner plusieurs lignes par groupe** de manière explicite et propre.

Cela arrive par exemple lorsqu'on calcule des quantiles, des top N …

La fonction `summarise()` est toujours valable et utilisable lorsqu'on souhaite **retourner une seule ligne par groupe** mais vous affichera un message d'avertissement lors des regroupements avec plusieurs lignes.

MINISTÈRE
DE L'AGRICULTURE
ET DE LA SOUVERAINETÉ
ALIMENTAIRE

Liberté
Égalité
Fraternité

2.9 La fonction reframe (3/4)

Exemple avec `summarise()` :

```
1 # Cette utilisation de summarise déclenche un avertissement
2 iris %>%
3   group_by(Species) %>%
4   summarise(q = quantile(Petal.Length, probs = c(0.25, 0.5, 0.75)))
```

```
# Groups:   Species [3]
  Species        q
  <fct>      <dbl>
1 setosa      1.4
2 setosa      1.5
3 setosa      1.58
4 versicolor  4
5 versicolor  4.35
6 versicolor  4.6
7 virginica   5.1
8 virginica   5.55
9 virginica   5.88
Warning message:
Returning more (or less) than 1 row per `summarise()` group was
```

Exemple avec `reframe()` :

```
1 # Pas d'avertissement avec reframe
2 iris %>%
3   group_by(Species) %>%
4   summarise(q = quantile(Petal.Length, probs = c(0.25, 0.5, 0.75)))
```

```
# A tibble: 9 × 2
  Species        q
  <fct>      <dbl>
1 setosa      1.4
2 setosa      1.5
3 setosa      1.58
4 versicolor  4
5 versicolor  4.35
6 versicolor  4.6
7 virginica   5.1
8 virginica   5.55
9 virginica   5.88
```

MINISTÈRE
DE L'AGRICULTURE
ET DE LA SOUVERAINETÉ
ALIMENTAIRE
Liberté
Égalité
Fraternité

2.10 La fonction reframe (4/4)

Quelques remarques supplémentaires entre `summarise()` et `reframe()` :

- `reframe()` renvoit toujours un data.frame **non groupé** tandis que `summarise()` peut renvoyer un data.frame groupé ou non en fonction du choix fait dans l'argument `.groups`.

Utilisation de `.groups` avec summarise() :

Valeur	Comportement
`"drop_last"` (défaut)	Supprime le dernier niveau de regroupement
`"drop"`	Supprime tous les groupements (df non groupée)
`"keep"`	Conserve tous les niveaux de groupement
`"rowwise"`	Groupe ligne à ligne

- Comme la fonction `summarise()`, la fonction `reframe()` **accepte l'argument `.by`** pour éviter d'écrire un group_by() et **est compatible avec la fonction across()** (voir plus loin).

MINISTÈRE
DE L'AGRICULTURE
ET DE LA SOUVERAINETÉ
ALIMENTAIRE

Liberté
Égalité
Fraternité

2.11 Fonctions utiles au traitement des chaînes de caractères

Problématique	Fonction R de base	Fonction du package stringr
Mettre x en majuscules	**toupper**(**x**)	**str_to_upper**(**x**)
Mettre x en minuscules	**tolower**(**x**)	**str_to_lower**(**x**)
Concaténer deux vecteurs	**paste**(**x**, **y**, sep = **" "**)	**str_c**(**x**, **y**, sep = **""**)
Connaître le nombre de caractères dans une chaîne	**nchar**(**x**) *Attention ! ≠ de length(x)*	**str_length**(**x**)
Extraire les caractères deb à fin dans une chaîne	**substr**(**x**, **deb**, **fin**)	**str_sub**(**x**, **deb**, **fin**)
Extraire les caractères à partir du deb^{eme} dans une chaîne	**substring**(**x**, **deb**)	**str_sub**(**x**, **deb**)
Supprimer les espaces de début et de fin	**trimws**(**x**)	**str_trim**(**x**)
Rajouter des caractères en début ou en fin de chaîne pour respecter un format (utile code dep)	-	**str_pad**(**x**, width = **longueur_format**, side = **"left"**, pad = **caractère_a_ajouter**)
Détecter la présence d'un motif dans une chaîne	**grepl**(**motif**, **x**, ignore.case = **F**)	**str_detect**(**x**, **motif**)
Remplacer un motif dans une chaîne	**gsub**(**motif**, **remplacement**, **x**)	**str_replace**(**x**, **motif**, **remplacement**)
Et bien d'autres encore !..		

MINISTÈRE
DE L'AGRICULTURE
ET DE LA SOUVERAINETÉ
ALIMENTAIRE

Liberté
Égalité
Fraternité

2.12 Tri dans une table

- Pour trier une table selon une ou plusieurs variables, on utilise la fonction *arrange()*

```
maTable %>% arrange(variables_de_tri)
```

→ possibilité de trier selon plusieurs colonnes : les variables de tri doivent être séparées par une virgule.

→ on encadre les variables qu'il faut trier de façon décroissante par la fonction *desc()*.

```
maTable %>% arrange(var1,desc(var2))
```

MINISTÈRE
DE L'AGRICULTURE
ET DE LA SOUVERAINETÉ
ALIMENTAIRE

Liberté
Égalité
Fraternité

2.13 Fusion de tables

- Pour fusionner deux tables en utilisant une ou plusieurs variables de jointure, on utilise les fonctions ***XXX_join()***

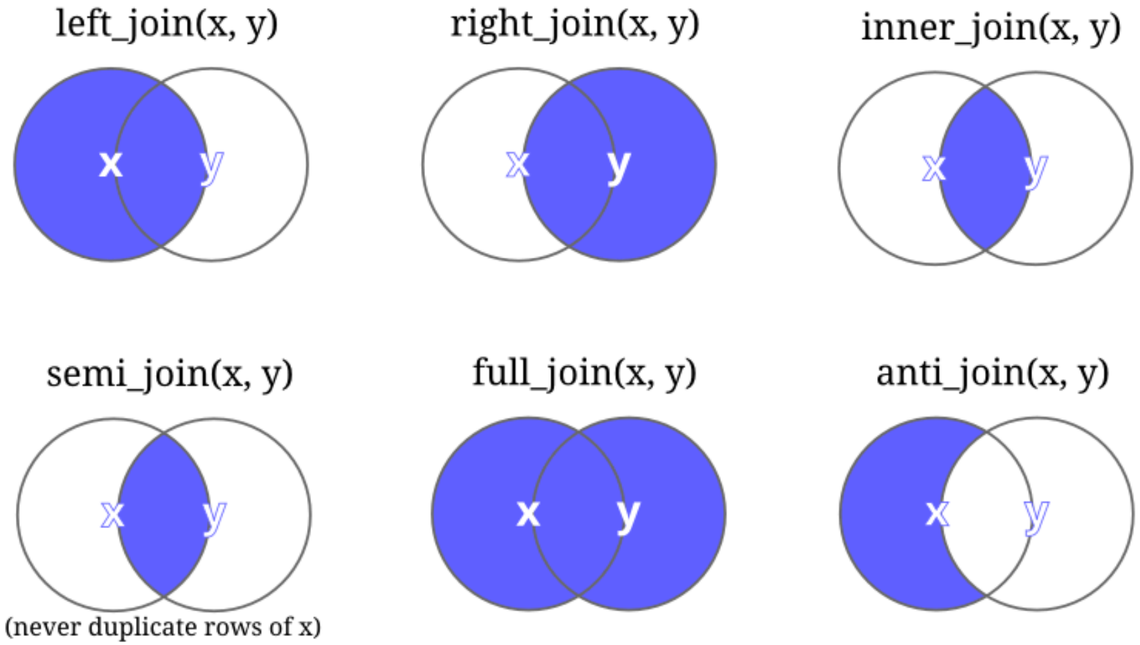

MINISTÈRE
DE L'AGRICULTURE
ET DE LA SOUVERAINETÉ
ALIMENTAIRE

Liberté
Égalité
Fraternité

2.14 Joindre des tables avec une variable de jointure

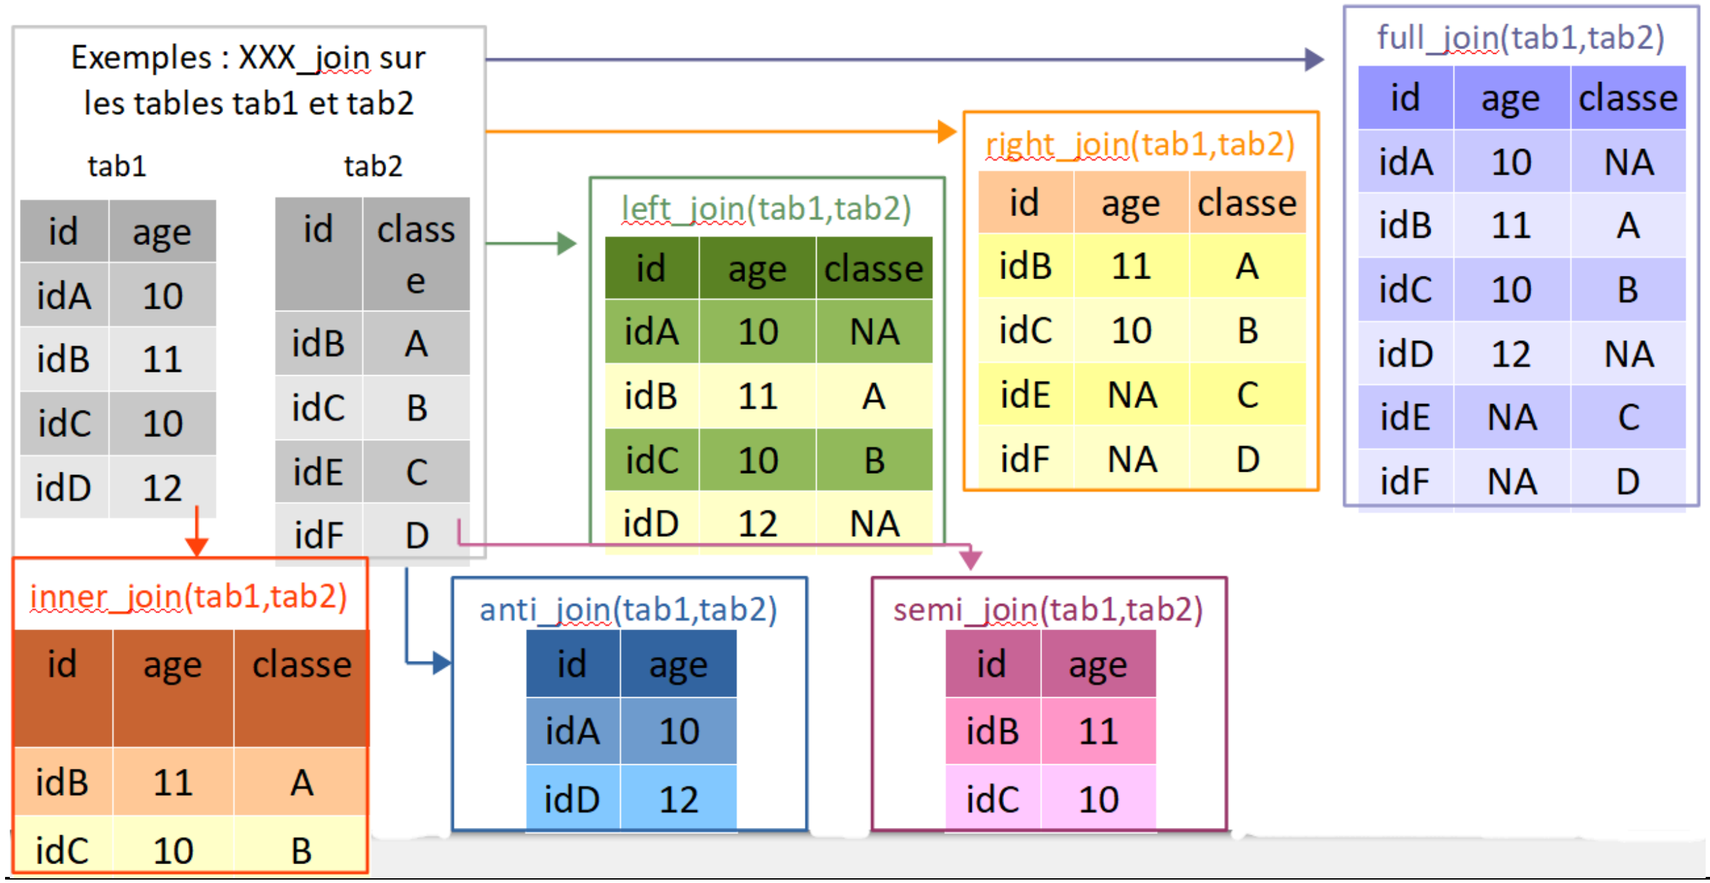

MINISTÈRE
DE L'AGRICULTURE
ET DE LA SOUVERAINETÉ
ALIMENTAIRE
Liberté
Égalité
Fraternité

2.15 Fusion de tables

- Syntaxe :

```
maTable1 %>% full_join(maTable2, by = "variable_de_jointure")
maTable1 %>% full_join(maTable2, by = join_by(id1_tab1==id1_tab2))
```

- Il est possible de réaliser une jointure à l'aide de plusieurs variables identifiantes : l'argument by s'écrit alors **c("id1","id2")** ou **join_by(id1,id2)**
- Lorsque les variables de jointure ont des noms différents dans les deux tables, l'argument by prend comme paramètre un vecteur du type **c("id1_tab1" = "id1_tab2","id2_tab1" = "id2_tab2",...)**
- Si rien n'est précisé, la fusion se fait sur l'ensemble des variables portant le même nom dans les deux tables

MINISTÈRE
DE L'AGRICULTURE
ET DE LA SOUVERAINETÉ
ALIMENTAIRE
Liberté
Égalité
Fraternité

2.16 Agrégation dans une table

- Pour résumer les données d'une table en une seule statistique, on utilise la fonction `summarise()`

```
maTable %>% summarise(fonctions_stat(variable))
```

- Pour agréger les données d'une table par groupe d'une ou plusieurs variables catégorielles on utilise la fonction ***group_by()*** avant la fonction ***summarise()***

```
maTable %>% group_by(var_groupe)%>% summarise(fonctions_stat(variable))
maTable %>% summarise(fonctions_stat(variable), .by=var_groupe)
```

→ possibilité de calculer plusieurs statistiques en séparant les instructions par une virgule

→ on peut utiliser les fonctions statistiques de base telles que max, min, mean, median, sqrt, sd, n,…

→ La fonction ungroup() permet de ne plus tenir compte du regroupement par la suite.

→ Voir également l'argument **.groups** de la fonction summarise() qui permet de gérer les niveaux de regroupement d'une table. Voir cet exemple.

MINISTÈRE
DE L'AGRICULTURE
ET DE LA SOUVERAINETÉ
ALIMENTAIRE

Liberté
Égalité
Fraternité

2.17 Transposition ou réorganisation de table (tidyr)

Pour réorganiser une table, c'est à dire passer des lignes en colonnes ou inversement, on utilise les fonctions `pivot_wider()` et `pivot_longer()` du package tidyr.

MINISTÈRE
DE L'AGRICULTURE
ET DE LA SOUVERAINETÉ
ALIMENTAIRE
Liberté
Égalité
Fraternité

2.18 pivot_wider()

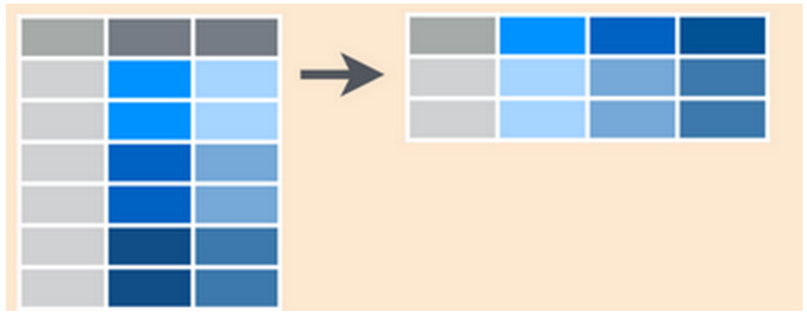

`maTable %>% pivot_wider(id_cols = col_restant, names_from = col_de_noms, values_from = col_de_valeurs)` les intitulés de colonne

- **col_restant** = nom des variables qui seront conservées telles quelles dans la table pivotée (par défaut toutes celles qui ne sont pas indiquées dans col_de_noms ou col_de_valeurs)
- **col_de_noms** = nom de la variable dont les modalités deviendront les intitulés de colonne
- **col_de_valeurs** = nom de la variable à utiliser pour remplir les colonnes

---

`maTable %>% pivot_wider(col_de_noms, col_de_valeurs)`

MINISTÈRE
DE L'AGRICULTURE
ET DE LA SOUVERAINETÉ
ALIMENTAIRE
Liberté
Égalité
Fraternité

2.19 pivot_longer()

```
maTable %>% pivot_longer( cols = variables_apivoter , names_to = "indicateur", values_to = "valeur")
```

- **variables_a_pivoter** = nom de l'ensemble des variables à représenter
- **names_to** = nom de la première colonne à créer
- **values_to** = nom de la deuxième colonne à créer

MINISTÈRE
DE L'AGRICULTURE
ET DE LA SOUVERAINETÉ
ALIMENTAIRE
Liberté
Égalité
Fraternité

2.20 Exemples sur les pivots

Ann	Mois	mesure	temperature
2020	janvier	min	- 10
2020	janvier	max	12
2020	janvier	moy	3
2020	février	min	- 6
2020	février	max	14
2020	février	moy	5

pivot_wider()

Ann	Mois	min	max	moy
2020	janvier	- 10	12	3
2020	février	- 6	14	5

pivot_longer()

```
tab2 ← pivot_wider( tab1, names_from = mesure, values_from = temperature)
tab1 ← pivot_longer(tab2, cols = c(min, max, moy), names_to = "mesure", values_to = "temperature")
```

MINISTÈRE
DE L'AGRICULTURE
ET DE LA SOUVERAINETÉ
ALIMENTAIRE

Liberté
Égalité
Fraternité

2.21 Autres fonctions utiles de dplyr et tidyr

- `case_when()` : en complément d'un mutate, pour modifier des valeurs ou modalités selon certaines conditions
- `slice()` et dérivés: une autre façon de filtrer les lignes (ex : n plus grandes/petites valeurs d'une variable)
- `distinct()` : gérer des doublons ou connaître les modalités d'une ou d'un groupe de variables
- `rename()` : renommer une variable (nouveau_nom=ancien_nom)
- `relocate()` : déplacer une variable (avec .after et .before)
- `count()` : compter le nombre d'observation pour chaque/un croisement de modalités
- `pull()`: pour extraire un vecteur à partir d'un data.frame
- `replace_na()` : remplacer toutes les valeurs manquantes NA par une valeur donnée ({tidyr})
- `drop_na()` : supprimer des lignes qui comportent des NA ({tidyr})

MINISTÈRE
DE L'AGRICULTURE
ET DE LA SOUVERAINETÉ
ALIMENTAIRE
Liberté
Égalité
Fraternité

2.22 Lecture ou écriture de fichiers (1/2)

Version courte: le package {rio} permet avec une seule fonction d'importer ou exporter quasiment tout type de fichier (.csv, .xlsx, .ods, .rds, .sas7bdat, .parquet, etc.)

Syntaxe de base :

- Import simple : `maTable <- import("V:/adresseMaTable/monFichierAImporter.csv")`
- Export simple : `export(maTable,"V:/adresseMaTable/monFichierAExporter.xlsx")`

{rio} est un package qui mobilise d'autres packages dédiés à certains types de fichier, (cf. **aide de rio** pour les connaître et spécifier certains paramètres) Ex: importer un seul onglet.

- `MaTable <- import("V:/adresseMaTable/monFichierAImporter.xlsx", sheet="monOnglet")` (paramètres de `readxl::read_excel()`)

MINISTÈRE
DE L'AGRICULTURE
ET DE LA SOUVERAINETÉ
ALIMENTAIRE
Liberté
Égalité
Fraternité

2.23 Lecture ou écriture de fichiers (2/2)

L'alternative est de passer par les fonctions des packages dédiés à chaque type de fichier:

Type	Lecture	Ecriture
Texte	`reader::read_delim()`	`reader::write_delim()`
RDS	`readr::read_rds()`	`readr::write_rds()`
XLS	les fonctions du package {readxl}	les fonctions du package {openxlsx}
SAS ou SPSS	`haven::read_sas()` et `haven::read_spss()`	Exporter au format texte puis lecture dans SAS ou SPSS (sans objet désormais)
ODS	`readODS::read_ods()`	`readODS::write_ods()`
Parquet	Les packages `arrow` et `duckdb`	Le package `arrow`

MINISTÈRE
DE L'AGRICULTURE
ET DE LA SOUVERAINETÉ
ALIMENTAIRE
Liberté
Égalité
Fraternité

2.24 Base de données avec R (avancé)

- R offre la possibilité d'effectuer des requêtes SQL sur des bases de données externes (il faut donc connaître la syntaxe SQL).
- Des informations pour la connexion sont nécessaires :

```
library(RPostgres)
cnx <- dbConnect(Postgres(), dbname = "sirene", port = 5432, host = "00.11.22.33", user = "nom_user", password = "mdp")
```

- Il suffit ensuite d'écrire les requêtes normalement à l'aide de la fonction dbGetQuery :

```
dbGetQuery(cnx, "SELECT * FROM TABLE")
```

MINISTÈRE
DE L'AGRICULTURE
ET DE LA SOUVERAINETÉ
ALIMENTAIRE

Liberté
Égalité
Fraternité

2.25 Exercices

Exercices

3 Les différents objets R

MINISTÈRE
DE L'AGRICULTURE
ET DE LA SOUVERAINETÉ
ALIMENTAIRE
Liberté
Égalité
Fraternité

3.1 Pourquoi faire du R de base ?

NB : on peut s'en sortir en manipulation de données sans connaître R de base grâce aux packages du tidyverse (mais ça aide quand même).

- Aide à mieux se servir de dplyr
- Déboguer des erreurs
- Solutions alternatives à dplyr dans certains cas
- **dplyr** moins adapté à la programmation et aux fonctions (problème de la *tidy evaluation*)
- Mieux comprendre le fonctionnement de R

MINISTÈRE
DE L'AGRICULTURE
ET DE LA SOUVERAINETÉ
ALIMENTAIRE
Liberté
Égalité
Fraternité

3.2 Les vecteurs : la brique de base

Objet élémentaire de R, une dimension (beaucoup de fonctions sont vectorisées)

- *NB : les colonnes (variables) de nos tableaux de données sont desvecteurs qui ont un nom (le nom de la variable)*
- Ensemble de valeurs, appelées éléments, **de même nature** (nombres entiers ou décimaux, chaînes de caractères, booléens…). Si ce n'est pas le cas, R va convertir. On peut donner un nom à chaque élément.
- Création de vecteurs avec la fonction c() ou `:` pour une suite de valeurs numériques :
  - `x <- c(TRUE, TRUE, FALSE) ; is.logical(x)`
  - `x <- c(a=8.04, b=18.01, c=11.05, d=14.05) ; is.numeric(x)`
  - `x <- c("Chaîne1", "804", "Chaîne3") ; is.character(x)`
  - `x <- 1:5`
  - `x <- rep(NA,10)`
  - `x <- seq(0,1,0.1)` (par exemple pour calculer des déciles)
- Fonctions utiles sur les vecteurs : `length()`, `class()`, `sort()`, `unique()`, `which()`, `as.<class>()`…

MINISTÈRE
DE L'AGRICULTURE
ET DE LA SOUVERAINETÉ
ALIMENTAIRE

Liberté
Égalité
Fraternité

3.3 Les vecteurs : exemples de code (1/2)

1er exemple :

```
# Création du vecteur y
y <- c(rep("a",5),rep("b",10),rep("c",5));
y
> [1] "a" "a" "a" "a" "a" "b" "b" "b" "b" "b" "b" "b" "b" "b" "b" "c" "c" "c" "c" "c"
as.factor(y)
> [1] a a a a a b b b b b b b b b b c c c c c
Levels: a b c
```

Les fonctions `which()` et `unique()` :

```
which(y=="a") # indices des éléments qui remplissent la condition
> [1] 1 2 3 4 5
unique(y) # enlève les doublons
> [1] "a" "b" "c"
```

L'opérateur `:` et la fonction `seq()` :

```
# Création d'un vecteur de 1 à 8
1:8
> [1] 1 2 3 4 5 6 7 8
# Création d'un vecteur de 0 à 1 avec un pas de 0.1
seq(0,1,0.1)
> [1] 0.0 0.1 0.2 0.3 0.4 0.5 0.6 0.7 0.8 0.9 1.0
```

MINISTÈRE
DE L'AGRICULTURE
ET DE LA SOUVERAINETÉ
ALIMENTAIRE
Liberté
Égalité
Fraternité

3.4 Les vecteurs : exemples de code (2/2)

- Exemple sur le type des vecteurs :

```
x <- c(1, "two", 3.0, TRUE,"29") # un vecteur ne peut être que d'une sorte
> [1] "1"    "two"  "3"    "TRUE" "29"
class(x)
> [1] "character"
```

- Tri et renversement des éléments d'un vecteur :

```
# Création du vecteur x
x <- sample(letters[1:10]);
# Tri des éléments du vecteur x
sort(x)
> [1] "a" "b" "c" "d" "e" "f" "g" "h" "i" "j"
# Renverse l'ordre des éléments du vecteur x
rev(sort(x))
> [1] "j" "i" "h" "g" "f" "e" "d" "c" "b" "a"
```

MINISTÈRE
DE L'AGRICULTURE
ET DE LA SOUVERAINETÉ
ALIMENTAIRE
Liberté
Égalité
Fraternité

3.5 Les data.frame : tables de données

Le **data.frame** est l'objet que l'on manipule le plus habituellement (tables du RA, etc.). C'est un tableau de données avec des lignes et des colonnes

- Formellement, un **data.frame** est composé de vecteurs nommés de tailles égales mais pouvant être de types différents (caractère, facteurs, numérique …).
- Création avec les fonctions `data.frame()`:

```
x <- data.frame(nom=c("Yaël","Luan","Jade"),    # 1er élément : un vecteur « nom » de trois chaînes de caractères`
                sexe = factor(c("H","F","F")),  # 2e élément : un vecteur « sexe » de trois chaînes de caractères (en facteurs)
                age = c(5,1,3))                 # 3e élément : un vecteur « age » de trois numériques
>
   nom sexe age
1 Yaël    H   5
2 Luan    F   1
3 Jade    F   3
```

MINISTÈRE
DE L'AGRICULTURE
ET DE LA SOUVERAINETÉ
ALIMENTAIRE
Liberté
Égalité
Fraternité

3.6 Fonctions utiles pour explorer des data.frame

- `str()` donne la structure de la table (ce que l'on voit dans l'environnement)
- `names()` le vecteur des noms de colonnes, `rownames()` le vecteur des noms de lignes (indices par défaut)
- `head()` et `tail()` affichent respectivement, par défaut, les 6 premières et les 6 dernières lignes de la table
- `dim()` renvoie un vecteur de 2 éléments composé du nombre de lignes et du nombre de colonnes de la table
- `summary()` renvoie un résumé du data.frame (utile pour explorer un jeu de données)

MINISTÈRE
DE L'AGRICULTURE
ET DE LA SOUVERAINETÉ
ALIMENTAIRE

Liberté
Égalité
Fraternité

3.7 Data.frame : exemples de code (1/3)

```r
maTable <- data.frame(
  cat=rep(letters[1:2],5),              # 5 Répétitions des lettres 'a' et 'b'
  var1= runif(10,max = 10),             # 10 valeurs aléatoires uniformément distribuées entre 0 et 10
  var2= rnorm(10,sd = 100),             # 10 valeurs tirées d'une distrib; normale avec une moy; de 0 et un sd de 100
  var3=c(rep(NA,3),sample(1:10,7,T)),   # 3 valeurs NA suivies de 7 valeurs aléatoires entre 1 et 10
  fact1=factor(rep(LETTERS[1:5],2)),    # un facteur composé de 2 répétitions des lettres 'A', 'B', 'C', 'D' et 'E'
  majuscule = LETTERS[1:10],            # les 10 premières lettres majuscules de l'alphabet
  logique=sample(c(T,F),10,T))          # 10 valeurs booléennes aléatoires
```

```
> maTable
   cat     var1       var2 var3 fact1 majuscule logique
1    a 8.625657   40.51943   NA     A         A   FALSE
2    b 6.394318  110.42277   NA     B         B    TRUE
3    a 7.351903   57.75785   NA     C         C    TRUE
4    b 7.222472  -39.86580    4     D         D    TRUE
5    a 7.297473 -186.24480    7     E         E   FALSE
6    b 2.516919  -39.21729   10     A         F   FALSE
7    a 0.143648  101.97522    9     B         G   FALSE
8    b 4.199952  -73.90209    8     C         H    TRUE
9    a 4.149988   15.82927   10     D         I   FALSE
10   b 8.856342   56.02326    1     E         J   FALSE
```

MINISTÈRE
DE L'AGRICULTURE
ET DE LA SOUVERAINETÉ
ALIMENTAIRE

Liberté
Égalité
Fraternité

3.8 Data.frame : exemples de code (2/3)

```
str(maTable)
> 'data.frame': 10 obs. of  7 variables:
 $ cat      : chr  "a" "b" "a" "b" ...
 $ var1     : num  8.43 8.77 8.71 9.88 3.02 ...
 $ var2     : num  -205.9 -87.3 -18.5 -261.6 -32 ...
 $ var3     : int  NA NA NA 2 6 1 1 9 10 2
 $ fact1    : Factor w/ 5 levels "A","B","C","D",..: 1 2 3 4 5 1 2 3 4 5
 $ majuscule: chr  "A" "B" "C" "D" ...
 $ logique  : logi  FALSE TRUE TRUE TRUE FALSE TRUE ...
```

```
summary(maTable) # noter la différence entre les vecteurs caractères et facteurs

>  cat                 var1           var2              var3        fact1  majuscule          logique
 Length:10          Min.   :3.020   Min.   :-261.589   Min.   : 1.000   A:2   Length:10          Mode :logical
 Class :character   1st Qu.:5.386   1st Qu.: -73.500   1st Qu.: 1.500   B:2   Class :character   FALSE:5
 Mode  :character   Median :7.979   Median :  -9.719   Median : 2.000   C:2   Mode  :character   TRUE :5
                    Mean   :7.012   Mean   : -38.531   Mean   : 4.429   D:2
                    3rd Qu.:8.651   3rd Qu.:  44.160   3rd Qu.: 7.500   E:2
                    Max.   :9.875   Max.   :  75.879   Max.   :10.000
                                                       NA's   :3
```

MINISTÈRE
DE L'AGRICULTURE
ET DE LA SOUVERAINETÉ
ALIMENTAIRE

Liberté
Égalité
Fraternité

3.9 Data.frame : exemples de code (3/3)

```
length(maTable) # pourquoi 7 ?
> [1] 7
dim(maTable)
> [1] 10  7
names(maTable)
[1] "cat"       "var1"      "var2"      "var3"      "fact1"     "majuscule" "logique"
```

MINISTÈRE
DE L'AGRICULTURE
ET DE LA SOUVERAINETÉ
ALIMENTAIRE
Liberté
Égalité
Fraternité

3.10 Les listes (un objet fourre-tout)

La **liste** est un objet apparemment moins usuel quand on débute avec `dplyr`, mais qui peut être très utile notamment à l'intérieur de fonctions (across), pour faire des boucles (purrr) ou bien quand on doit ranger dans un unique objet, des objets de toute sorte.

- Une **liste** est composée d'objets de types et tailles différents (peut-être très utile en sortie de fonction).
- Création avec la fonctions `list()` :

```
x ← list(c(TRUE, TRUE, FALSE),           # 1er élément : un vecteur de trois booléens
         c(8.04, 18.01, 11.05, 14.05),   # 2e élément : un vecteur de quatre numériques
         c("804"))                        # 3e élément : un vecteur d'une chaîne de caractères
```

NB : un data.frame est une liste de vecteurs de même taille.

MINISTÈRE
DE L'AGRICULTURE
ET DE LA SOUVERAINETÉ
ALIMENTAIRE

Liberté
Égalité
Fraternité

3.11 Listes : exemples de code (1/2)

```r
# En nommant chaque élément de la liste
list(mesLettres=letters,
     monDF = data_frame(letters,LETTERS),
     ma2eListe=list("toto",1:10))

# > $mesLettres
 [1] "a" "b" "c" "d" "e" "f" "g" "h" "i" "j" "k" "l" "m" "n" "o" "p" "q" "r" "s" "t" "u" "v" "w" "x" "y" "z"

$monDF
# A tibble: 26 × 2
   letters LETTERS
   <chr>   <chr>
 1 a       A
 2 b       B
 3 c       C
# ℹ 24 more rows
# ℹ Use `print(n = ...)` to see more rows
```

```r
$ma2eListe
$ma2eListe[[1]]
[1] "toto"

$ma2eListe[[2]]
 [1]  1  2  3  4  5  6  7  8  9 10
```

MINISTÈRE
DE L'AGRICULTURE
ET DE LA SOUVERAINETÉ
ALIMENTAIRE

Liberté
Égalité
Fraternité

3.12 Listes : exemples de code (2/2)

```
# Sans donner de noms
liste1 <- list(1:10)

liste2 <- list(letters)

# Concaténation des 2 listes
c(liste1,liste2)

>
[[1]]
 [1]  1  2  3  4  5  6  7  8  9 10

[[2]]
 [1] "a" "b" "c" "d" "e" "f" "g" "h" "i" "j" "k" "l" "m" "n" "o" "p" "q" "r" "s" "t" "u" "v" "w" "x" "y" "z"
```

MINISTÈRE
DE L'AGRICULTURE
ET DE LA SOUVERAINETÉ
ALIMENTAIRE
Liberté
Égalité
Fraternité

3.13 Les matrices

Objets moins utilisés en traitement de données usuel, plus en statistiques.

- Une matrice est composée d'un ou de plusieurs **éléments de mêmes types**, organisés en **deux dimensions**.
- Création de matrice avec la fonction `matrix()` :

```r
# Création d'une matrice de numériques avec deux lignes et trois colonnes, remplissage par colonne.`
exemple_matrice  <- matrix(c(1,2,3,4,5,6), nrow = 2, ncol = 3)

#      [,1] [,2] [,3]
# [1,]    1    3    5
# [2,]    2    4    6

#Transposée
t(exemple_matrice)
#      [,1] [,2]
# [1,]    1    2
# [2,]    3    4
# [3,]    5    6
```

- Fonctions utiles : `dim()`, `nrow()`, `ncol()`, `t()`...

MINISTÈRE
DE L'AGRICULTURE
ET DE LA SOUVERAINETÉ
ALIMENTAIRE

Liberté
Égalité
Fraternité

4 Naviguer à l'intérieur des objets R (indexation)

MINISTÈRE
DE L'AGRICULTURE
ET DE LA SOUVERAINETÉ
ALIMENTAIRE

Liberté
Égalité
Fraternité

4.1 Pour quoi faire?

- Extraire un élément d' un objet (ex : tous les nombres supérieurs à 10)
- Remplacer un élément par un autre (ex : remplacer toutes les chaînes "Bov." par "Bovins")
- Ajouter un élément (ex : une nouvelle variable à un data.frame)

```r
nombres <-  1:20
nombres[nombres>10]

# > [1] 11 12 13 14 15 16 17 18 19 20

mes_lettres <- letters[1:5]
mes_lettres[3] <- "g"
mes_lettres

# > [1] "a" "b" "g" "d" "e"

mon_df <- data.frame(letters,LETTERS)
mon_df["concat"] <- paste0(letters,LETTERS)
mon_df[1,]

# >   letters LETTERS concat
1       a       A     aA
```

MINISTÈRE
DE L'AGRICULTURE
ET DE LA SOUVERAINETÉ
ALIMENTAIRE

Liberté
Égalité
Fraternité

4.2 Vecteur, indexation avec les crochets:

- Indexation **par position** :

```
x <- c("Marion", "Benjamin", "Hélène", "Raymond"))
x[1] renvoie "Marion"
x[c(1, 2)] renvoie le vecteur c("Marion", "Benjamin")
```

- Indexation **par condition logique** :

```
x <- c(8.04, 18.01, 11.05, 14.05)
x[x < 10] renvoie 8.04
x[x > 10] renvoie le vecteur c(18.01, 11.05, 14.05)
x[x >10 & x < 15] renvoie le vecteur c(11.05, 14.05)
```

MINISTÈRE
DE L'AGRICULTURE
ET DE LA SOUVERAINETÉ
ALIMENTAIRE

Liberté
Égalité
Fraternité

4.3 Data.frame (1/3) : principes de navigation

- Indexation **par position** : [numéro de ligne, numéro de colonne]
- Indexation **par nom** : les vecteurs d'une data.frame sont nommés et accessibles directement dans les crochets ou via l'opérateur `$`
- Les moyens d'indexation peuvent se combiner et permettre de filtrer les colonnes et les lignes (équivalent de `select()` et `filter()`)

→ Il y a donc une multitude de façons d'accéder à une valeur dans un data.frame !

MINISTÈRE
DE L'AGRICULTURE
ET DE LA SOUVERAINETÉ
ALIMENTAIRE
Liberté
Égalité
Fraternité

4.4 Data.frame (2/3) : illustration

Tab_ind

Prenom	Sexe	Taille
Pierre	H	185
Anne	F	167
Marie	F	171
Charles	H	175

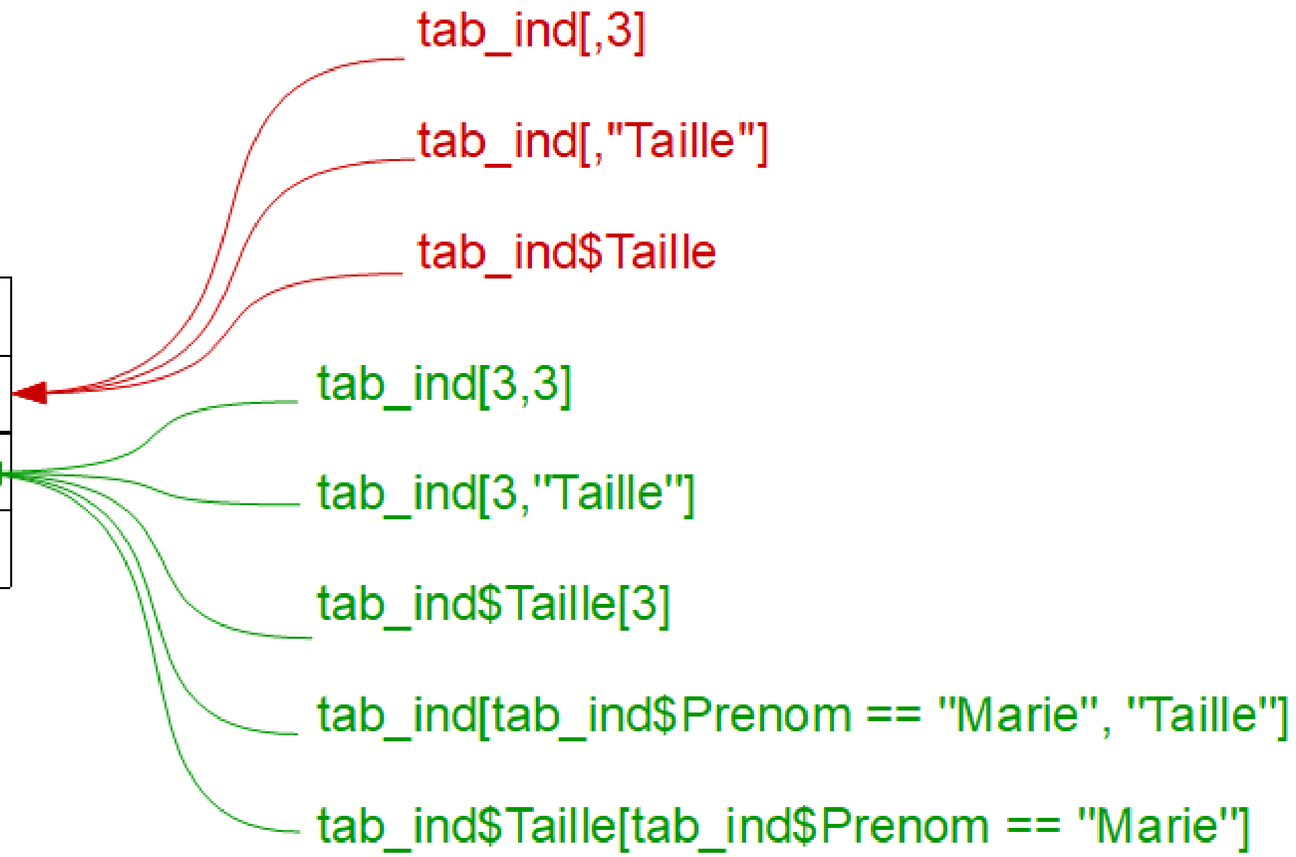

MINISTÈRE
DE L'AGRICULTURE
ET DE LA SOUVERAINETÉ
ALIMENTAIRE

Liberté
Égalité
Fraternité

4.5 Data.frame (3/3) : exemple de code

Quelques lignes de code utiles en R de base :

```
1
2 mon_df <- data.frame(letters,LETTERS) # création du data.frame avec les lettres de l'alphabet
3 mon_df[1,] # un data.frame avec uniquement la 1ère ligne
4 mon_df[,1] # un vecteur avec la 1ère colonne,
5 mon_df["letters"] # attention si pas de virgule, renvoie un data.frame d'une seule colonne
6 mon_df[["letters"]] # pour extraire le vecteur, il faut mettre deux crochets
7 mon_df$letters[1:4]  # avec le symbole $ on a aussi un vecteur qu'on peut indexer aussi (4 premières valeurs)
```

MINISTÈRE
DE L'AGRICULTURE
ET DE LA SOUVERAINETÉ
ALIMENTAIRE
Liberté
Égalité
Fraternité

4.6 Création ou modification de variables dans un data.frame en R de base

Avec **R de base**, on utilise l'opérateur d'affectation :

- `table$new_var <- variable` → formule générique
- `table$new_var <- valeur_constante` → création d'une constante
- `table$new_var <- fonction(table$var1)` → création à partir d'une formule
- `table$new_var <- table$var1 + table$var2` → création à partir d'opérations
- `table$new_var <- vecteur1 OU table1$new_var <- table2$var1` → création à partir de variables externes
- `table$new_var <- ifelse(table$varref < x, val1, val2)` OU `table$new_var <- case_when(table$varref < x ~ val1, TRUE ~ val2)` → traitement conditionnel

MINISTÈRE
DE L'AGRICULTURE
ET DE LA SOUVERAINETÉ
ALIMENTAIRE
Liberté
Égalité
Fraternité

4.7 Listes (1/2)

Indexation par position :

```
x <- list(c(TRUE, TRUE, FALSE), c(8.04, 18.01, 11.05, 14.05), "804")
```

=> `x[[2]]` renvoie le deuxième vecteur de la liste x soit `c(8.04, 18.01, 11.05, 14.05)`

=> `x[[2]][1]` renvoie le premier élément du deuxième vecteur de la liste x soit `8.04`

Note

Attention :
`x[2]` avec de simples crochets, renvoie une liste composée d'un élément : le 2e vecteur de la liste x

MINISTÈRE
DE L'AGRICULTURE
ET DE LA SOUVERAINETÉ
ALIMENTAIRE
Liberté
Égalité
Fraternité

4.8 Listes (2/2)

Indexation par nom :

```
x <- list(grp = c("Auguste", "Justine", "Sébastien", "Anne-Marie"), prt = c("Hélène", "Raymond"), enf = c("Marion", "Benjamin")
```

=> `x$grp` renvoie le vecteur nommé "grp" de la liste x soit `c("Auguste", "Justine", "Sébastien", "Anne-Marie")`

=> `x$enf[1]` renvoie le premier élément du vecteur nommé "enf" de la liste x soit `"Marion"`

Possibilité d'utiliser la fonction `pluck()` du package {purrr} (+ pratique pour éviter de s'y perdre)

```
x <- list(c(TRUE, TRUE, FALSE), c(8.04, 18.01, 11.05, 14.05), "804")
```

=> `pluck(x,2)` renvoie le deuxième vecteur de la liste x soit `c(8.04, 18.01, 11.05, 14.05)`
=> `pluck(x,2,1)` renvoie le premier élément du deuxième vecteur de la liste x soit `8.04`

MINISTÈRE
DE L'AGRICULTURE
ET DE LA SOUVERAINETÉ
ALIMENTAIRE

Liberté
Égalité
Fraternité

4.9 Matrices, indexation avec les crochets:

Création d'une matrice :

```
x <- matrix(c("Marion", "Benjamin", "Hélène", "Raymond"), nrow = 2, ncol = 2)
```

```
     [,1]       [,2]
[1,] "Marion"   "Hélène"
[2,] "Benjamin" "Raymond"
```

Indexation **par position** :

=> `x[1,]` renvoie le vecteur `c("Marion", "Hélène")`

=> `x[,2]` renvoie le vecteur `c("Hélène", "Raymond")`

=> `x[2,1]` renvoie `"Benjamin"`